

Projekt z zakresu eksploracji danych

Projekt indywidualny

Projekt 8

Inżynieria i analiza danych 2024/25
Politechnika Lubelska
Wydział Matematyki i Informatyki Technicznej

Piotr Szyszka

Spis treści

1	Wstęp	2
2	Zadanie 1.	3
2.1	Rozwiązanie zadania 1.	3
3	Zadanie 2	6
3.1	Rozwiązanie zadania 2.	6
4	Zadanie 3	8
4.1	Rozwiązanie zadania 3	8
4.1.1	Uzupełnienie braków X2	9
4.1.2	Uzupełnienie braków X3	10
4.1.3	Uzupełnienie braków X7	11
4.1.4	Uzupełnienie braków X4	12
4.1.5	Uzupełnienie braków X1	13
4.1.6	Uzupełnienie braków X5	14

1 Wstęp

W niniejszym dokumencie zaprezentowano rozwiązanie zadań projektu indywidualnego realizowanego w ramach przedmiotu *Projekt z zakresu eksploracji danych*.

Analiza danych została przeprowadzona przy użyciu języka programowania R oraz programu MS Excel. Raport natomiast został opracowany w środowisku [Quarto](#).

Tabela 1: Kilka przykładowych rekordów opracowywanych danych

X1	X2	X3	X4	X5	X6	X7
35.7	73.5	151.8	-148.98	14.0	48.7	96.7
26.6	18.3	41.1	-1.92	17.5	44.6	88.3
49.3	29.9	64.5	8.94	16.8	52.0	104.5
40.1	31.5	67.7	-14.26	19.7	51.3	102.9
65.3	60.7	126.3	-51.52	21.3	51.1	103.0
67.5	30.3	64.7	44.17	16.6	50.8	102.4

Dane, których podzbiór przedstawiono w Tabela 1 składają się z siedmiu zmiennych, które charakteryzują się tym, że wszystkie zmienne są typu numerycznego. W związku z tym do ich szczegółowego opisu można wykorzystać zestaw miar statystycznych, takich jak średnia, mediana, czy odchylenie standardowe, które pozwolą na pełniejsze zrozumienie rozkładu i zmienności tych danych.

2 Zadanie 1.

Dla każdej zmiennej wyznaczyć i zinterpretować wartości podstawowych statystyk.

2.1 Rozwiązanie zadania 1.

Za podstawowe statystyki opisowe uważa się:

- *wartość minimalną* – najmniejsza wartość w danych,
- *średnią* - miara tendencji centralnej,
- *kwartyle* ($Q1$, $Q2$, $Q3$) - opisują rozkład danych:
 - **Q1** - wartość, poniżej której znajduje się 25% danych;
 - **Q2** - czyli po prostu mediana; oznacza to, że 50% danych ma wartość mniejszą od $Q2$, a 50% większą;
 - **Q3** - określa górną ćwiartkę danych, czyli wartość, poniżej której znajduje się 75% danych
- *wartość maksymalną* - największa wartość w zbiorze danych,
- *odchylenie standardowe* - miara rozproszenia, która opisuje rozproszenie danych wokół średniej,
- *dominantę* - wartość najczęściej występującą w zbiorze danych.

Tabela 2: Podstawowe statystyki opisowe

	X1	X2	X3	X4	X5	X6	X7
Min.	20.0	10.0	4.06	-3124.51	3.8	34.7	-911.3
1st Qu.	32.5	28.5	61.56	-98.79	16.6	46.7	93.3
Median	44.6	45.2	94.76	-46.56	19.9	50.1	100.3
Mean	45.8	45.8	96.49	-45.79	20.5	50.5	101.0
3rd Qu.	57.3	62.6	129.50	5.98	23.4	53.4	106.8
Max.	2044.9	1064.1	2132.92	3855.32	1031.4	1050.0	2099.5
Std.	47.3	30.4	63.15	130.17	23.2	23.0	56.1
NA's	1.0	3.0	2.00	1.00	2.0	1.0	3.0

Na podstawie statystyk przedstawionych w tabeli 'Tabela 2 zauważyć można, że:


- w zbiorze występują braki danych dla każdej z kolumn,
- brak dominanty oznacza, że każda z wartości występuje tylko raz w każdej ze zmiennych,

- dla każdej zmiennej jej średnia i mediana są zbliżone do siebie, co wskazuje na symetrię rozkładu,
- zgodnie z zasadą, że typowy zakres zmienności to $\bar{x} \pm \sigma_x$, mamy:

$$\begin{aligned} X_1 : & 45.78 \pm 47.34, \\ X_2 : & 45.83 \pm 30.44, \\ X_3 : & 96.49 \pm 63.15, \\ X_4 : & -45.79 \pm 130.17, \\ X_5 : & 20.49 \pm 23.24, \\ X_6 : & 50.54 \pm 22.98, \\ X_7 : & 101.04 \pm 56.11; \end{aligned}$$

- we wszystkich zmiennych występują obserwacje odstające – różnica między trzecim kwartylem (Q_3) a wartością maksymalną w każdej z kolumn jest bardzo duża w porównaniu z miarami tendencji centralnej tych zmiennych.

Własności rozkładu dobrze jest również zobrazować za pomocą wykresu pudełkowego (*ang. box plot*).



Rysunek 1: Wykresy pudełkowe zmiennych

Na wykresach pudełkowych przedstawionych na Rysunek 1 zauważyć można występujące obserwacje odstające.

 Ważne

Podjęto decyzję o usunięciu zidentyfikowanych obserwacji odstających we wszystkich kolumnach. Filtracji obserwacji odstających dokonano wykorzystując rozstęp międzykwartylowy (*ang. interquantile range*) - wszystkie obserwacje x z każdej z kolumn spełniające warunek:

$$x < Q1 - 1.5 \cdot IQR \vee x > Q3 + 1.5 \cdot IQR, \quad IQR = Q3 - Q1$$

zostaną wyrzucone ze zbioru danych.

Statystyki po usunięciu zostały zaprezentowane w Tabeli 3. Po tym zabiegu zauważyć można, że w kolumnie $X6$ nie występują już braki danych.

Tabela 3: Statystyki zmiennych po usunięciu obserwacji odstających

	X1	X2	X3	X4	X5	X6	X7
Min.	20.0	10.0	4.06	-243.47	6.70	36.76	73.2
1st Qu.	32.3	28.4	61.30	-98.72	16.72	46.67	93.4
Median	44.6	45.2	94.76	-46.47	19.90	50.13	100.3
Mean	44.6	45.2	94.82	-46.32	20.00	50.04	100.1
3rd Qu.	57.2	62.4	129.08	5.97	23.35	53.30	106.6
Max.	70.0	110.9	226.26	103.70	33.37	63.05	126.4
Std.	14.5	20.1	40.20	66.57	4.89	4.84	9.7
NA's	1.0	3.0	2.00	1.00	2.00	0.00	3.0

Największe zróżnicowanie (mierzone odchyleniem standardowym) występuje dla zmiennej $X4$ (66.57), co wskazuje na duże rozproszenie wartości wokół średniej. Zmienna ta ma również wartości ekstremalne, od -243.47 do 103.70 . Z kolei najmniejsze zróżnicowanie występuje dla zmiennej $X5$ (4.89).

Niektóre zmienne mają szeroki zakres wartości, np. $X3$ (od 4.06 do 226.26) i $X4$ (od -243.47 do 103.70). Może to wskazywać na znaczną różnorodność w danych.

3 Zadanie 2

Dla zmiennej X_1 utworzyć szereg rozdzielczy przedziałowy o 10 przedziałach i wyznaczyć wartości statystyk.

3.1 Rozwiązanie zadania 2.

Dla zmiennej X_1 mamy:

- $k = 10$ (liczba przedziałów),
- $x_{1_{max}} = 70$ (wartość największa),
- $x_{1_{min}} = 20$ (wartość najmniejsza),
- $R = x_{1_{max}} - x_{1_{min}} = 49.9$ (zakres zmienności X_1),
- $h = \frac{R}{k} = 4,99$ (długość jednego przedziału)

Szereg rozdzielczy przedstawiony został w tabeli Tabela 4.

Tabela 4: Szereg rozdzielczy zmiennej X_1

x_l	x_r	x_i	n_i
20	25	22.5	207
25	30	27.5	208
30	35	32.5	190
35	40	37.5	219
40	45	42.5	172
45	50	47.5	205
50	55	52.5	176
55	60	57.5	207
60	65	62.5	186
65	70	67.5	195

Podstawowe statystyki opisowe zostały przedstawione w Tabeli 5. Zauważyć można, że statystyki oszacowane za pomocą szeregu rozdzielczego są zbliżone co do wartości obliczonych na całym zbiorze.

Tabela 5: Zestaw statystyk zmiennej X1 obliczonych na podstawie szeregu rozdzielczego oraz wartości dokładnych

	Series	Population	Abs. diff
Mean	44.6	44.6	0.013
Q1	32.5	32.3	0.203
Q2	42.5	44.6	2.107
Q3	57.5	57.2	0.268
Std. dev	14.4	14.5	0.067

4 Zadanie 3

Uzupełnić braki danych.

4.1 Rozwiązanie zadania 3

Liczbę braków danych dla wszystkich zmiennych przedstawiono w Tabeli 6.

Tabela 6: Liczba braków dla wszystkich zmiennych

	X1	X2	X3	X4	X5	X6	X7
Liczba braków	1	3	2	1	2	0	3

Aby jak najdokładniej uzupełnić brakujące dane, kluczowe jest zbadanie zależności między zmiennymi w zbiorze. Istnieje możliwość, że zmienne te są ze sobą powiązane, a odkrycie tych zależności może stanowić istotną wskazówkę w procesie imputacji. W szczególności, jeśli uda się wyrazić jedną zmienną w zależności od innych, można wykorzystać tę wiedzę do oszacowania brakujących wartości.

Adnotacja


Współczynnik korelacji Pearsona służy do zbadania jedynie zależności liniowej między zmiennymi. Oznacza to, że nawet jeśli korelacja Pearsona jest bliska zeru, nie musi to oznaczać braku jakiegokolwiek zależności — może istnieć nieliniowa zależność, którą ten współczynnik nie uchwyci.

Zależności zmiennych wyrażone za pomocą współczynnika korelacji przedstawiono na Rysunek 2. Zauważyć można, że pary zmiennych $(X6, X7)$ oraz $(X2, X3)$ są ze sobą współliniowe - oznacza to, że brakującą wartość jednej z nich można precyzyjnie oszacować na podstawie wartości drugiej. Wysoką korelację obserwujemy również dla par $(X3, X4)$ i $(X2, X4)$.

Zmienną najsilniej skorelowaną z $X1$ jest $X4$ na poziomie 0.42.

Adnotacja

Przy analizie korelacji warto uwzględnić test istotności, jednak w przypadku próby liczącej około 2000 obserwacji, testowanie istotności zostało pominięte. Wynika to z tego, że przy tak dużej próbie moc testu jest na tyle wysoka, że nawet istotne korelacje mogą zostać uznane za nieistotne.



Rysunek 2

4.1.1 Uzupełnienie braków X2

Braki danych zmiennej X_2 przedstawione zostały w Tabeli 7. Dla tych braków, znane są wartości innych zmiennych, dzięki czemu możliwe jest uzupełnienie ich wykorzystując zależności pomiędzy zmiennymi.

Tabela 7: Braki dla zmiennej X_2

X1	X2	X3	X4	X5	X6	X7
42.7	NA	4.06	85.5	22.2	50.7	101
28.7	NA	4.97	57.3	26.8	53.7	107
38.4	NA	4.45	76.7	20.8	58.8	117

Do uzupełnienia braków zmiennej X_2 wykorzystamy jej liniową zależność z X_3 . Liniowy model regresji przedstawiony został w Tabeli 8 - $R^2 = 1$ wskazuje na perfekcyjne dopasowanie.

Tabela 8: Podsumowanie modelu do imputowania braków w kolumnie X2 ($X2 \sim X3$)

	(1)
(Intercept)	-2.229
	(0.008)
X3	0.500
	(0.000)
R2	1.000
R2 Adj.	1.000
RMSE	0.14

Uzupełnione wartości dla zmiennej X2 przedstawione zostały w Tabela 9.

Tabela 9: Uzupełnione braki danych dla zmiennej X2

X1	X2	X3	X4	X5	X6	X7
42.7	-0.199	4.06	85.5	22.2	50.7	101
28.7	0.256	4.97	57.3	26.8	53.7	107
38.4	-0.004	4.45	76.7	20.8	58.8	117

4.1.2 Uzupełnienie braków X3

Braki danych w kolumnie X3 przedstawiono w Tabela 10.

Tabela 10: Braki dla zmiennej X3

X1	X2	X3	X4	X5	X6	X7
45.4	43.6	NA	-40.1	28.8	51.3	103.5
51.9	68.5	NA	-101.7	18.4	46.3	93.5

Do uzupełnienia braków w kolumnie X3 możemy wykorzystać jej liniowy związek z X2. Model regresji dla X3 przedstawiony został w Tabela 11. W tym przypadku również osiągnięto R^2 na poziomie 1.

Tabela 11: Podsumowanie modelu do imputowania braków w kolumnie X3 ($X3 \sim X2$)

	(1)
(Intercept)	4.464
	(0.016)
X2	2.001
	(0.000)
R2	1.000
R2 Adj.	1.000
RMSE	0.28

Uzupełnione wartości przedstawione zostały w Tabeli 12.

Tabela 12: Uzupełnione braki danych dla zmiennej X3

X1	X2	X3	X4	X5	X6	X7
45.4	43.6	91.7	-40.1	28.8	51.3	103.5
51.9	68.5	141.5	-101.7	18.4	46.3	93.5

4.1.3 Uzupełnienie braków X7

Tabela 13: Braki danych zmiennej X7

X1	X2	X3	X4	X5	X6	X7
54.9	61.2	127.2	-73.8	7.84	44.5	NA
54.2	79.9	164.8	-131.3	16.93	53.5	NA
68.3	37.2	78.9	24.9	11.93	55.7	NA

Do uzupełnienia braków zmiennej $X7$ wykorzystamy jej liniową zależność z $X6$. Model liniowy ma postać przedstawioną w Tabeli 14.

Tabela 14: Podsumowanie modelu do imputowania braków w kolumnie X7 ($X7 \sim X6$)

	(1)
(Intercept)	0.119 (0.134)
X6	1.998 (0.003)
R2	0.997
R2 Adj.	0.997
RMSE	0.57

Dane po imputacji przedstawiono w Tabeli 15.

Tabela 15: Uzupełnione braki danych dla zmiennej X7

X1	X2	X3	X4	X5	X6	X7
54.9	61.2	127.2	-73.8	7.84	44.5	89
54.2	79.9	164.8	-131.3	16.93	53.5	107
68.3	37.2	78.9	24.9	11.93	55.7	111

4.1.4 Uzupełnienie braków X4

Tabela 16: Braki zmiennej X4

X1	X2	X3	X4	X5	X6	X7
39.8	30.1	65.2	NA	18.2	37.9	75.8

Mając na uwagę korelacje zmiennej $X4$ z $X2$, $X3$ oraz $X1$, możemy z tych zmiennych zbudować model liniowy do uzupełnienia tych braków. Aby zapobiec redundancji zmiennych, do modelu włączymy albo $X2$, albo $X3$, ale nie obie (ponieważ są współliniowe).

Model do uzupełnienia braków zmiennej $X4$ przedstawiono w Tabeli 17.

Tabela 17: Model do uzupełnienia braków w X4 ($X4 \sim X1 + X2$)

	(1)
(Intercept)	0.000 (0.000)
X1	2.000 (0.000)
X2	-3.000 (0.000)
R2	1.000
R2 Adj.	1.000
RMSE	0.00

Uzupełnione wartości przedstawiono w Tabeli 18.

Tabela 18: Uzupełnione braki danych zmiennej X4

X1	X2	X3	X4	X5	X6	X7
39.8	30.1	65.2	-10.8	18.2	37.9	75.8

4.1.5 Uzupełnienie braków X1

Tabela 19: Braki dla zmiennej X1

X1	X2	X3	X4	X5	X6	X7
NA	36	76.7	-108	17.7	53.4	107

Do uzupełnienia braków w X1 wykorzystamy model zbudowany z wykorzystaniem X2 i X4, którego podsumowanie przedstawia Tabela 20.

Tabela 20: Podsumowanie modelu do imputowania braków w X1 ($X1 \sim X2 + X4$)

	(1)
(Intercept)	0.000 (0.000)
X2	1.500 (0.000)
X4	0.500 (0.000)
R2	1.000
R2 Adj.	1.000
RMSE	0.00

Wartości po uzupełnieniu przedstawia Tabela 21.

Tabela 21: Uzupełnione wartości zmiennej X1

X1	X2	X3	X4	X5	X6	X7
0	36	76.7	-108	17.7	53.4	107

4.1.6 Uzupełnienie braków X5


Braki zmiennej X5 przedstawione zostały w tabeli Tabela 22.

Tabela 22: Braki dla zmiennej X5

X1	X2	X3	X4	X5	X6	X7
49.8	12.4	29.4	62.4	NA	61.7	123.3
37.7	70.9	145.9	-137.3	NA	48.6	97.9

W przypadku zmiennej X5 nie występuje silna zależność liniowa z innymi zmiennymi w zbiorze danych. Ponadto, brakujące wartości są tylko dwoma danymi, co stanowi minimalny ułamek całkowitej liczby obserwacji. Mając na uwadze symetryczny charakter rozkładu tej zmiennej, *uzupełnienie brakujących wartości za pomocą średniej (lub mediany) jest uzasadnione.*

```
`stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```



Rysunek 3: Histogram zmiennej X5

Uzupełnione średnią wartości braki danych zmiennej X5 przedstawione zostały w Tabela 23.

Tabela 23: Uzupełnione braki danych zmiennej X5

X1	X2	X3	X4	X5	X6	X7
49.8	12.4	29.4	62.4	20	61.7	123.3
37.7	70.9	145.9	-137.3	20	48.6	97.9